Asembliranje genoma

Vladimir Mijić

27. mart 2024.

- Genom genetski materijal nekog organizma
 - genom se nalazi u DNK ili RNK molekulima

- Genom genetski materijal nekog organizma
 - genom se nalazi u DNK ili RNK molekulima
- Nukleotid osnovni gradivni molekul DNK i RNK
 - adenin, citozin, guanin, timin (DNK) ili uracil (RNK)

- Genom genetski materijal nekog organizma
 - genom se nalazi u DNK ili RNK molekulima
- Nukleotid osnovni gradivni molekul DNK i RNK
 - adenin, citozin, guanin, timin (DNK) ili uracil (RNK)
- Ljudski genom sadrži oko 3 milijarde nukleotida

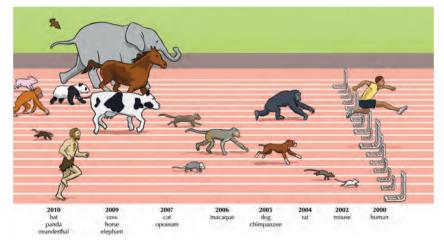
- Genom genetski materijal nekog organizma
 - genom se nalazi u DNK ili RNK molekulima
- Nukleotid osnovni gradivni molekul DNK i RNK
 - adenin, citozin, guanin, timin (DNK) ili uracil (RNK)
- Ljudski genom sadrži oko 3 milijarde nukleotida
- Sekvenciranje genoma predstavlja proces otkrivanja sastava genoma

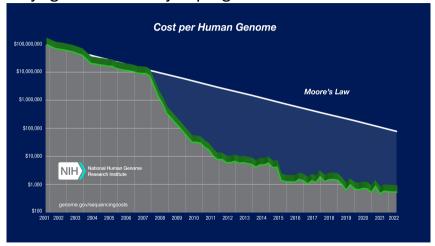
- 1977. Prve metode za sekvenciranja DNK
 - Sangerova metoda Frederick Sanger
 - Maxam Gilbert metoda Allan Maxam i Walter Gilbert

- 1977. Prve metode za sekvenciranja DNK
 - Sangerova metoda Frederick Sanger
 - Maxam Gilbert metoda Allan Maxam i Walter Gilbert
- Problem?

- 1977. Prve metode za sekvenciranja DNK
 - Sangerova metoda Frederick Sanger
 - Maxam Gilbert metoda Allan Maxam i Walter Gilbert
- Problem?
 - Predložene metode su bile izuzetno skupe \$3 milijarde dolara za sekvenciranje ljudskog genoma

- 1977. Prve metode za sekvenciranja DNK
 - Sangerova metoda Frederick Sanger
 - Maxam Gilbert metoda Allan Maxam i Walter Gilbert
- Problem?
 - Predložene metode su bile izuzetno skupe \$3 milijarde dolara za sekvenciranje ljudskog genoma
- 1990. Početak projekta Human Genome Project
 - Cilj: sekvenciranje ljudskog genoma
 - Prvi rezultati objavljeni 2001. godine
 - Završen 2003. godine

















Slika: Problem eksplozije novina će poslužiti u razumijevanju problema asembliranja genoma

a shirt, appuse have rot yet named a mation is welc

shirt, approximately 6'2" 18 tyet named any suspects is welcomec. Please can

Slika: Spajanje dijelova koji se preklapaju

 Kopije novina - odgovaraju uzorcima DNK

- Kopije novina odgovaraju uzorcima DNK
- Dijelovi novina odgovaraju očitanjima sekvenciranja

- Kopije novina odgovaraju uzorcima DNK
- Dijelovi novina odgovaraju očitanjima sekvenciranja
 - Sekvencer sječe genom na manje dijelove koji se nazivaju očitavanja (eng. reads)
 - Neki dijelovi će biti izgubljeni

- Kopije novina odgovaraju uzorcima DNK
- Dijelovi novina odgovaraju očitanjima sekvenciranja
 - Sekvencer sječe genom na manje dijelove koji se nazivaju očitavanja (eng. reads)
 - Neki dijelovi će biti izgubljeni
- Cilj spojiti dijelove u jednu cjelinu



Slika: Nije isto kao slaganje slagalice!

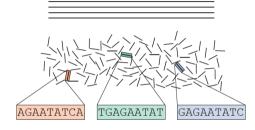
Ilustracija problema

Multiple identical copies of a genome

Shatter the genome into reads

Sequence the reads

Assemble the genome using overlapping reads



AGAATATCA GAGAATATC TGAGAATAT

...TGAGAATATCA...

Asembliranje genoma je težak problem.

Prije uvođenja formulisanja računarskog problema, navešćemo neke ključne karakteristike problema:

• DNK je dvostruki lanac nukleotida - nije poznato iz kog lanca proizilazi koje očitanje

Asembliranje genoma je težak problem.

Prije uvođenja formulisanja računarskog problema, navešćemo neke ključne karakteristike problema:

- DNK je dvostruki lanac nukleotida nije poznato iz kog lanca proizilazi koje očitanje
- Očitanja mogu sadržati greške

Asembliranje genoma je težak problem.

Prije uvođenja formulisanja računarskog problema, navešćemo neke ključne karakteristike problema:

- DNK je dvostruki lanac nukleotida nije poznato iz kog lanca proizilazi koje očitanje
- Očitanja mogu sadržati greške
- Očitanja ne pokrivaju cijeli genom

Asembliranje genoma je težak problem.

Prije uvođenja formulisanja računarskog problema, navešćemo neke ključne karakteristike problema:

- DNK je dvostruki lanac nukleotida nije poznato iz kog lanca proizilazi koje očitanje
- Očitanja mogu sadržati greške
- Očitanja ne pokrivaju cijeli genom

Očitavanja su iste dužine, možemo pretpostaviti da su očitavanja svi k-grami (eng. k-mer, podniska dužine k) za neko k.

Računarska formulacija problema asembliranja genoma: Za dati string Text, njegova k-gram kompozicija $COMPOSITION_3$ (Text) je kolekcija svih k-gram podniski od Text. Primjer:

 $COMPOSITION_3$ (TATGGGGTGC) = {ATG, GGG, GGG, GGT, GTG, TAT, TGC, TGG}

k-grami su prikazani u leksikografskom poretku, zato što tačan redoslijed očitavanja nije poznat kada se generišu.

Rekonstruisati nisku iz njenih k-grama.

Ulaz: Vrijednost *k* i kolekcija k-grama *Patterns*.

Izlaz: Niska Text koja sadrži sve k-grame iz Patterns, ako takva niska postoji.

Neka je zadata 3-gram kompozicija

AAT ATG GTT TAA TGT

Neka je zadata 3-gram kompozicija

AAT ATG GTT TAA TGT

Zadatak: povežimo parove k-grama ako se preklapaju u k-1 simbola.

Neka je zadata 3-gram kompozicija

AAT ATG GTT TAA TGT

Zadatak: povežimo parove k-grama ako se preklapaju u k-1 simbola.

TAA
AAT
ATG
TGT
GTT

Slika: Rekonstruisana niska je *TAATGTT*

Neka je zadata 3-gram kompozicija

AAT ATG ATG ATG CAT CCA GAT GCC GGA GGG GTT TAA TGC TGG TGT

AAT ATG ATG ATG CAT CCA GAT GCC GGA GGG GTT TAA TGC TGG TGT

TAA AAT ATG TAATG

Slika: ATG može biti povezan sa TGC, ili TGG, ili TGT

AAT ATG ATG ATG CAT CCA GAT GCC GGA GGG GTT TAA TGC TGG TGT

TAA
AAT
ATG
TGT

Slika: Kako smo izabrali TGT, jedini sljedeći izbor je GTT

AAT ATG ATG CAT CCA GAT GCC GGA GGG GTT TAA TGC TGG TGT

TAA
AAT
ATG
TGT
GTT
TAATGTT

Slika: Ne možemo nastaviti dalje jer nema k-grama koji počinju sa TT

AAT ATG ATG ATG CAT CCA GAT GCC GGA GGG GTT TAA TGC TGG TGT

TAA
AAT
ATG
TGC
TAATGC

Slika: Vraćamo se na k-gram ATG i nastavljamo dalje sa TGC

AAT ATG ATG ATG CAT CCA GAT GCC GGA **GGG** GTT TAA TGC TGG TGT

```
TAA
AAT
ATG
TGC
GCC
CCA
CAT
ATG
TGG
GGA
GAT
ATG
TGT
GTT
TAATGCCATGGATGTT
```

Slika: Nastavliaiući dalie, dobili smo TAATGCCATGGATGTT ali nismo iskoristili k-gram GGG

AAT ATG ATG ATG CAT CCA GAT GCC GGA GGG GTT TAA TGC TGG TGT

Slika: Ovo je jedno od mogućih rješenja, korištene su različite boje za interval između pojavljivanja ATG

Problem rekonstrukcije niske - grafovska reprezentacija

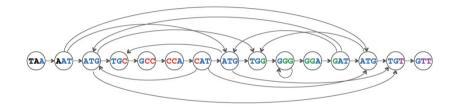
• Čvorovi grafa su k-grami

Problem rekonstrukcije niske - grafovska reprezentacija

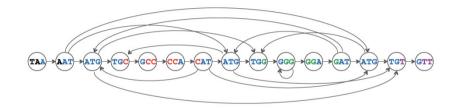
- Čvorovi grafa su k-grami
- Grane su usmjerene, od čvora *a* do čvora *b* postoji grana ako:
 - suffix(a) == prefix(b)

$$\begin{array}{c} (\textbf{TAA}) \rightarrow (\textbf{ATG}) \rightarrow (\textbf{TGC}) \rightarrow (\textbf{GCC}) \rightarrow (\textbf{CCA}) \rightarrow (\textbf{CAT}) \rightarrow (\textbf{ATG}) \rightarrow (\textbf{TGG}) \rightarrow (\textbf{GGG}) \rightarrow (\textbf{GAT}) \rightarrow (\textbf{ATG}) \rightarrow (\textbf{TGT}) \rightarrow (\textbf{GTT}) \rightarrow (\textbf{TGT}) \rightarrow (\textbf{T$$

Slika: Genomska putanja TAATGCCATGGGATGTT

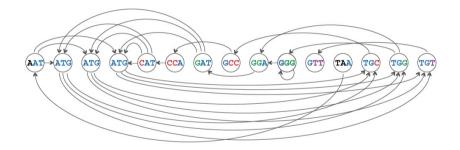


Slika: Graf na osnovu k-gramskog sastava

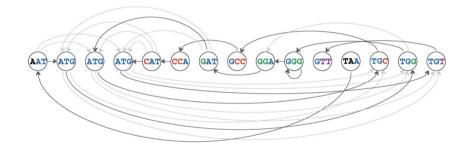


Slika: Graf na osnovu k-gramskog sastava

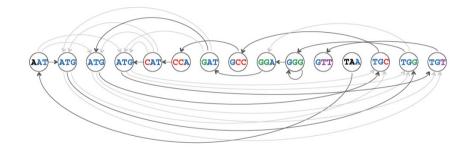
Možemo li pronaći genomsku putanju u ovom grafu?



Slika: Graf na osnovu k-gramskog sastava, sortiran po leksikografskom poretku



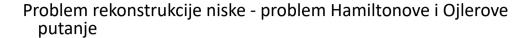
Slika: Genomska putanja TAATGCCATGGGATGTT



Slika: Genomska putanja TAATGCCATGGGATGTT

Da li je ovo jedino rješenje?

Hamiltonova putanja



Hamiltonova putanja - putanja koja prolazi kroz sve **čvorove** grafa tačno jednom.

Hamiltonova putanja - putanja koja prolazi kroz sve **čvorove** grafa tačno jednom.

• Problem pronalaska Hamiltonove putanje je NP-težak - nema efikasnog algoritma za rješavanje

Hamiltonova putanja - putanja koja prolazi kroz sve čvorove grafa tačno jednom.

 Problem pronalaska Hamiltonove putanje je NP-težak - nema efikasnog algoritma za rješavanje

Ojlerova putanja

Hamiltonova putanja - putanja koja prolazi kroz sve čvorove grafa tačno jednom.

 Problem pronalaska Hamiltonove putanje je NP-težak - nema efikasnog algoritma za rješavanje

Ojlerova putanja - putanja koja prolazi kroz sve grane grafa tačno jednom.

Hamiltonova putanja - putanja koja prolazi kroz sve čvorove grafa tačno jednom.

 Problem pronalaska Hamiltonove putanje je NP-težak - nema efikasnog algoritma za rješavanje

Ojlerova putanja - putanja koja prolazi kroz sve grane grafa tačno jednom.

 Problem pronalaska Ojlerove putanje nije NP-težak - postoji efikasan algoritam za rješavanje

Hamiltonova putanja - putanja koja prolazi kroz sve čvorove grafa tačno jednom.

 Problem pronalaska Hamiltonove putanje je NP-težak - nema efikasnog algoritma za rješavanje

Ojlerova putanja - putanja koja prolazi kroz sve grane grafa tačno jednom.

- Problem pronalaska Ojlerove putanje nije NP-težak postoji efikasan algoritam za rješavanje
- Potrebno je drugačije definisati graf

Predstavljanje k-gramskog sastava na drugačiji način:

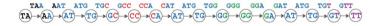
- Čvorovi grafa su k-1-grami
 - Izlazni čvor će biti prefiks k-grama
 - Ulazni čvor će biti sufiks k-grama

Predstavljanje k-gramskog sastava na drugačiji način:

- Čvorovi grafa su k-1-grami
 - Izlazni čvor će biti prefiks k-grama
 - Ulazni čvor će biti sufiks k-grama
- Grane su označene k-gramom

Predstavljanje k-gramskog sastava na drugačiji način:

- Čvorovi grafa su k-1-grami
 - Izlazni čvor će biti prefiks k-grama
 - Ulazni čvor će biti sufiks k-grama
- Grane su označene k-gramom

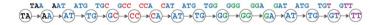


Slika: Grafovska reprezentacija za TAATGCCATGGGATGTT

3-grami su grane, 2-grami su čvorovi

Predstavljanje k-gramskog sastava na drugačiji način:

- Čvorovi grafa su k-1-grami
 - Izlazni čvor će biti prefiks k-grama
 - Ulazni čvor će biti sufiks k-grama
- Grane su označene k-gramom



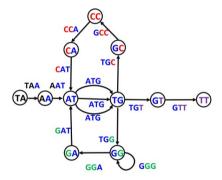
Slika: Grafovska reprezentacija za TAATGCCATGGGATGTT

Neki čvorovi imaju istu oznaku, možemo li ih spojiti?

Sve čvorove koji imaju istu oznaku je moguće spojiti u jedan čvor, zadržavajući sve grane. Takav graf se naziva **De Bruijnov graf**.

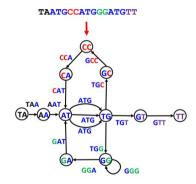
Problem rekonstrukcije niske - problem Ojlerove putanje Sve čvorove koji imaju istu oznaku je moguće spojiti u jedan čvor, zadržavajući sve grane.

Takav graf se naziva **De Bruijnov graf**.

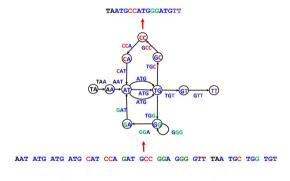


Slika: De Bruijnov graf za TAATGCCATGGGATGTT

Problem rekonstrukcije niske - De Brujinov graf od k-grama Vidjeli smo kako od zadate niske (genoma) možemo konstruisati De Brujinov graf. U realnim primjenama, potrebno je konstruisati graf od k-grama (očitavanja).



Slika: Genom \rightarrow De Bruijnov graf



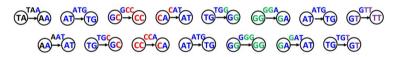
Slika: Očitavanja ightarrow De Bruijnov graf ightarrow genom

Postupak:

 Za svaki k-gram kreiramo dva čvora i jednu granu, jedan čvor predstavlja prefiks, a drugi sufiks k-grama

Postupak:

 Za svaki k-gram kreiramo dva čvora i jednu granu, jedan čvor predstavlja prefiks, a drugi sufiks k-grama



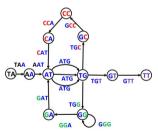
 Čvorove sa istom oznakom spajamo u jedan dok ne dobijemo graf sa jedinstvenim čvorovima

Postupak:

- Za svaki k-gram kreiramo dva čvora i jednu granu, jedan čvor predstavlja prefiks, a drugi sufiks k-grama
- Čvorove sa istom oznakom spajamo u jedan dok ne dobijemo graf sa jedinstvenim čvorovima



- Za svaki k-gram kreiramo dva čvora i jednu granu, jedan čvor predstavlja prefiks, a drugi sufiks k-grama
- Čvorove sa istom oznakom spajamo u jedan dok ne dobijemo graf sa jedinstvenim čvorovima



Slika: De Bruijnov graf za TAATGCCATGGGATGTT

Ojlerova teorema

Svaki Ojlerov graf je balansiran.

Svaki povezan graf i balansiran graf je Ojlerov.

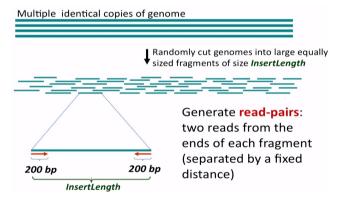
Povezan graf je graf u kojem postoji put između svaka dva čvora.

```
EULERIANCYCLE(Graph)
form a cycle Cycle by randomly walking in Graph (don't visit the same edge twice!)
while there are unexplored edges in Graph
select a node newStart in Cycle with still unexplored edges
form Cycle' by traversing Cycle (starting at newStart) and then randomly walking
Cycle ← Cycle'
```

return Cycle

Slika: Pseudokod algoritma EulerianCycle

- Problem: Postojanje više Ojlerovih putanja u De Brujinovom grafu
- Rješenje: Sekvenciranje sa parovima očitavanja



Upareni k-gram predstavlja par k-grama na fiksiranom rastojanju d u genomu.



Slika: TCA i TCC na rastojanju d=11 čine jedan upareni 3-gram

Upareni k-gramski sastav *PairedComposition_d* (*Text*) se sastoji od svih k-grama niske *Text* i njihovih parova.

PairedComposition(TAATGCCATGGGATGTT)

```
TAA GCC

AAT CCA

ATG CAT

TGC ATG

GCC TGG

CCA GGG

CAT GGA

ATG GAT

TGG ATG

GGG TGT

GGA GTT
```

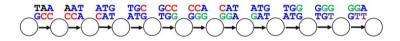
Slika: PairedComposition₃ (TAATGCCATGGGATGTT)



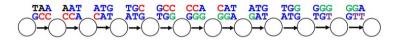
Slika: Leksikografski poredak kolekcije PairedComposition₃ niske TAATGCCATGGGATGTT

Problem rekonstrukcije niske na osnovu parova očitavanja:

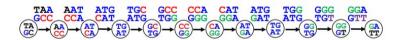
- Ulaz: Kolekcija uparenih k-grama
- Izlaz: Niska Text takva da je PairedComposition_k (Text) jednak kolekciji uparenih k-grama



Slika: Genom TAATGCCATGGGATGTT predstavljen kao putanja

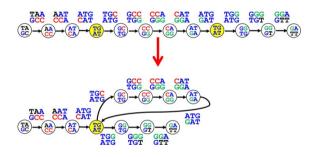


Slika: Genom TAATGCCATGGGATGTT predstavljen kao putanja



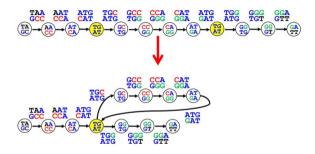
Slika: Graf koji odgovara uparenom 3-gramskom sastavu TAATGCCATGGGATGTT

Grana - upareni 3-gram, čvor - prefiks i sufiks uparenog 3-grama



Slika: Upareni De Brujinov graf za TAATGCCATGGGATGTT

Dva čvora (TG AT) su spojeni u jedan čvor



Slika: Upareni De Brujinov graf za TAATGCCATGGGATGTT

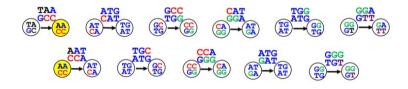
Dva čvora (TG AT) su spojeni u jedan čvor Kako konstruisati upareni De Brujinov graf na osnovu uparenih k-grama?

Upareni De Brujinov graf na osnovu kolekcije uparenih k-grama:

- Svaka grana je označena jednim uparenim k-gramom
- Svaki čvor je označen prefiksom/sufiksom izlazne/ulazne grane
- Čvorovi sa istom oznakom se spajaju u jedan čvor

Sastavljanje parova očitavanja Upareni De Brujinov graf na osnovu kolekcije uparenih k-grama:

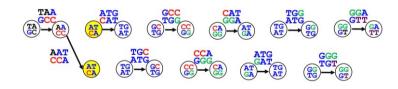
- Svaka grana je označena jednim uparenim k-gramom
- Svaki čvor je označen prefiksom/sufiksom izlazne/ulazne grane
- Čvorovi sa istom oznakom se spajaju u jedan čvor



Slika: Konstrukcija uparenog De Brujinovog grafa na osnovu uparenih k-grama

Sastavljanje parova očitavanja Upareni De Brujinov graf na osnovu kolekcije uparenih k-grama:

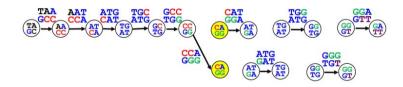
- Svaka grana je označena jednim uparenim k-gramom
- Svaki čvor je označen prefiksom/sufiksom izlazne/ulazne grane
- Čvorovi sa istom oznakom se spajaju u jedan čvor



Slika: Konstrukcija uparenog De Brujinovog grafa na osnovu uparenih k-grama

Sastavljanje parova očitavanja Upareni De Brujinov graf na osnovu kolekcije uparenih k-grama:

- Svaka grana je označena jednim uparenim k-gramom
- Svaki čvor je označen prefiksom/sufiksom izlazne/ulazne grane
- Čvorovi sa istom oznakom se spajaju u jedan čvor



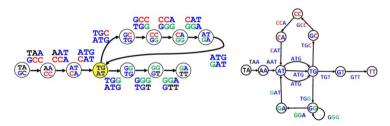
Slika: Konstrukcija uparenog De Brujinovog grafa na osnovu uparenih k-grama

Iterativnim spajanjem čvorova dobijamo upareni De Brujinov graf

TAATGCCATGGGATGTT

TAATGCCATGGGATGTT

TAATGGGATGCCATGTT



Slika: Poređenje uparenog De Brujinovog grafa i običnog De Brujinovog grafa

Lijevo - jedinstvena rekonstrukcija genoma, desno - više mogućih rekonstrukcija genoma

U realnosti
Do sada smo pretpostavljali da su očitavanja savršena i da ne sadrže greške. Ali, u ralnosti

Očitavanja sadrže greške

Očitavanja sadrže greške

```
atgccgtatggacaacgact
atgccgtatg
gccgtatgga
gtatggacaa
gacaacgact
```

```
atgccgtatggacaacgact
atgcc
 gccgt
   ccqta
    cgtat
     gtatg
      tatgg
       atgga
        tggac
         ggaca
          gacaa
           acaac
             caacq
             aacqa
              acgac
                cgact
```

- Očitavanja sadrže greške
- Rastojanja između očitavanja u parovima nisu tačna

- Očitavanja sadrže greške
- Rastojanja između očitavanja u parovima nisu tačna



- Očitavanja sadrže greške
- Rastojanja između očitavanja u parovima nisu tačna
- Nesavršena pokrivenost genoma očitavanjima

Hvala na pažnji!

Reference

- Phillip Compeau, Pavel Pevzner, Bioinformatics Algorithms 2nd Edition, 2015.
- Bioinformatics Algorithms video predavanja
- Predavanja iz kursa Uvod u bioinformatiku, prof. dr Jovana Kovačević MATF